


Local LLM - AI Locale

“AI” privata, offline e sicura.



Obiettivo del mini-corso

Alla fine: chatbot agentico locale privato con RAG per applicazioni real-world.

Parte 1: modello locale

Parte 2: client UI

Parte 3: RAG

Cos'è un Local LLM?

Un modello linguistico eseguito sul proprio hardware, senza chiamare sempre un servizio cloud.

AI, ML, reti neurali, LLM, chatbot, etc...

AI - Artificial Intelligence

Categoria ampia: sistemi che imitano capacità cognitive.

ML - Machine Learning

Modelli che imparano pattern dai dati.

LLM - Large Language Model

Reti neurali addestrate su linguaggio e codice.

NN - Neural Networks

Modelli computazionali ispirati alle reti neurali biologiche

GenAI - Generative AI

Ai che genera contenuti (testuali, visivi, audio, etc...)


SLM - Small Language Model

LLM ma piccoli

● GERARCHIA

Non sono sinonimi

- Rete neurale: architettura di calcolo
- LLM: modello linguistico grande
- Chatbot: prodotto o interfaccia



Come funziona un LLM?

Predice il prossimo token usando il contesto precedente.

- Token $\approx$ pezzi di testo
- Context window = memoria temporanea
- Output = probabilità, non verità



Tokenizzazione e context window

- Il testo viene spezzato in token
- Il contesto ha un limite
- Più contesto = più costo e latenza

Tokens	Characters
87	445

lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Text Token IDs

A helpful rule of thumb is that one token generally corresponds to ~4 characters of text for common English text. This translates to roughly $\frac{3}{4}$ of a word (so 100 tokens $\approx$ 75 words).

● CLOUD

Provider “closed source” principali

Comodi, potenti, ma controllati da terzi.

OpenAI

Anthropic

Google

Microsoft

xAI



OpenAI


Gemini

ANTHROPIC

MOTIVAZIONE


Perché LLM locali?

- Privacy e dati sensibili
- Uso offline
- Controllo su modello e configurazione
- Costi prevedibili su uso intensivo
- Reliability



Quanto “locale” e’ locale?

- Prompt e file restano locali solo se non usi servizi esterni
- Estensioni e browser possono aggiungere rischi
- Ricerca online = non sei più offline
- Controlla sempre impostazioni e permessi



● OPEN SOURCE?

Open source ≠ open weights

Open source

Codice, licenza aperta, diritti chiari di modifica e redistribuzione.

Open weights

Pesi scaricabili, ma training data e pipeline spesso non aperti.

Licenza

Può limitare uso commerciale, modifica o redistribuzione.

Cosa controllare prima di usare un modello

Uso

Personale, ricerca, didattica, commerciale.

Redistribuzione

Posso condividerlo o integrarlo in un prodotto?

Model card

Limiti, lingua, benchmark, formato, rischi noti.

Perché NO local?

- GPU e RAM costano
- Modelli piccoli sono meno capaci
- Setup e manutenzione
- Cloud spesso vince su comodità

NVIDIA Latest Gen	
H200 SXM ★ featured 141 GB VRAM 188 GB RAM • 12 vCPU	\$3.99/hr 8 max High
H100 SXM 80 GB VRAM 125 GB RAM • 20 vCPU	\$2.99/hr 2.49/hr 8 max High
L40S 48 GB VRAM 62 GB RAM • 16 vCPU	\$0.86/hr 0.73/hr 7 max Medium
RTX 6000 Ada 48 GB VRAM 62 GB RAM • 16 vCPU	\$0.77/hr 0.65/hr 8 max Medium
B200 ★ featured 180 GB VRAM 283 GB RAM • 36 vCPU	\$7.99/hr 6.99/hr 8 max Low
H100 NVL 94 GB VRAM 94 GB RAM • 16 vCPU	\$2.79/hr 2.49/hr 8 max Low

Cos'è quindi un chatbot?

La catena minima funzionante

Client UI → inference engine → modello

Browser UI



Inference Server



LLM locale

Intermezzo

Inference: come giriamo tutto?

Serve un motore che carica il modello e genera risposte.

Prima di procedere...

Hardware

RAM disponibile, spazio disco, eventuale GPU.

Software

Terminale, browser compatibile, permessi installazione.

Rete

Serve internet per scaricare Ollama e i modelli.

● ENGINE

Inference engine: panoramica

Ollama

Facile, ottimo per desktop e demo.

llama.cpp


CPU/GPU, quantizzazioni, GGUF.

vLLM

Server GPU ad alte prestazioni.

Perché Ollama?

- Installazione semplice
- Download modelli via CLI
- Server API locale
- Ottimo per didattica e demo



Power OpenClaw with Ollama

**The easiest way to build
with open models**

Parte Pratica 1: Ollama

- Scaricare e installare Ollama
- Verificare: `ollama --version`
- Scaricare un modello piccolo
- Provare: `ollama run ...`
- Tenere Ollama attivo

Dove si trovano?

Hugging Face è il catalogo principale per modelli, dataset e demo.

- Cercare modello e licenza
- Leggere model card
- Controllare formato e requisiti



The AI community building the future.

The platform where the machine learning community collaborates on models, datasets, and applications.

Explore AI Apps

or

[Browse 2M+ models](#)

● SCELTA

Come scegliere un modello

Task

Chat, coding, visione, documenti, tool use.

Hardware


RAM/VRAM disponibili e velocità attesa.

Licenza

Uso personale, ricerca, commerciale.

Esempio Pratico: LM Arena


- Confronti tra modelli
- Ranking basato su preferenze
- Utile, ma non assoluto



BENCHMARK

Benchmark: utili, ma parziali

- Misurano task specifici
- Possono essere contaminati
- Non sostituiscono una prova reale



State of the Art delle LLM “open weights”

Ogni famiglia ha dimensioni, licenze e specializzazioni diverse.

Llama

Qwen

Mistral

Gemma


DeepSeek



● TIPI DI BASE

Completion vs instruct

- Completion: continua un testo
- Instruct: segue istruzioni e chat
- Per chatbot: di solito instruct



● THINKING MODE

Thinking, non-thinking, hybrid

Non-thinking

Risposte dirette, spesso più veloci.

Thinking

Più passaggi interni, spesso più lento.

Hybrid

Può alternare modalità in base al task.

Text vs visual

- Text-only: prompt e documenti testuali
- Vision: immagini, screenshot, diagrammi
- Multimodale $\neq$ onnisciente
- Input multimodale $\neq$ output multimodale


VLM



Vision
Encoder




Text
Encoder



Language
Model


Dense vs MoE

- Dense: più semplice da capire
- MoE: attiva solo parti del modello
- Parametri totali $\neq$ costo per token
- GPU vs CPU



Formato modelli e Ollama

- Ollama scarica modelli dalla sua library
- Molti modelli derivano da GGUF/quant
- Da Hugging Face si può importare con Modelfile



● MEMORIA

Parametri e (V)RAM


- 7B ≈ leggero
- 30B ≈ più qualità, più memoria
- 70B+ ≈ hardware serio o cloud



Quantizzazione

Meno bit per peso = meno memoria,
spesso un po' meno qualità.

- Q4: molto leggero
- Q5/Q6: buon compromesso
- Q8/FP16: più qualità, più memoria



● SCELTA DEMO

Scegliamo Qwen 3.5

- Molte dimensioni disponibili
- Supporto thinking e vision
- Buon compromesso per demo locale



● DEMO

Modello demo vs modello produzione

Modello produzione

Più capace, più pesante, utile per mostrare qualità.

Modello demo

Piccolo, veloce, deve girare su tutti.

Obiettivo

Capire come scegliere il modello.

Scaricare e provare

```
ollama run qwen3.5:0.8b
```

```
> Hello World!
```

Details

Updated 1 month ago

f3817196d142 · 1.0GB ·

model arch `qwen35` · parameters `873M` · quantization `Q8_0` 1.0GB

license Apache License Version 2.0, January 2004 <http://www.apache.org/licenses/> 11kB

params { "presence_penalty": 1.5, "temperature": 1, "top_k": 20, "top_p": ... } 65B

Problemi comuni

- ollama non trovato → riaprire terminale / PATH
- porta 11434 non raggiungibile → avviare ollama serve
- download lento → modello piccolo o rete diversa
- RAM insufficiente → modello più piccolo / contesto ridotto
- Inference lenta → /set nothink

Prompt test

- 1) Capitale della Francia
- 2) Presidente Stati Uniti
- 3) Cosa sei tu?
- 4) Matematica facile
- 5) Rispondi con x caratteri.

How to Write Good LLM Prompts

- ✓ Be specific and clear
- ✓ Structure the prompts
- ✓ Provide context
- ✓ Ask open-ended questions
- ✓ Ask for examples
- ✓ Avoid ambiguity
- ✓ Tailor prompts to model capabilities
- ✓ Be concise and comprehensive

Accendere / spegnere il reasoning

- Dipende dal modello
- Può aumentare tempo e token
- Utile per problemi complessi

Thinking Mode	Non-Thinking Mode
<pre>< im_start >user {query} /think< im_end > < im_start >assistant <think> {thinking_content} </think> {response}< im_end ></pre>	<pre>< im_start >user {query} /no_think< im_end > < im_start >assistant <think> </think> {response}< im_end ></pre>

Prompt stress-test

- 1) Autolavaggio.
- 2) 9.11 vs 9.9
- 3) R in strawber(rrr)ry
- 4) Matematica
- 5) Rispondi con x caratteri.

Rank	Model	Score (AVG@5)	Organization
-	Highest Human Score*	95.4%	
-	Human Baseline*	83.7%	
1st	Gemini 3.1 Pro Preview	79.6%	Google
2nd NEW	GPT-5.5 Pro	76.9%	OpenAI
3rd	Gemini 3 Pro Preview	76.4%	Google
4th NEW	GPT-5.5	69.0%	OpenAI
5th	Claude Opus 4.6	67.6%	Anthropic
6th	Gemini 2.5 Pro (06-05)	62.4%	Google
7th	Claude Opus 4.5	62.0%	Anthropic
8th NEW	Claude Opus 4.7	61.7%	Anthropic

Cosa osservare nella risposta

Qualità

Correttezza, chiarezza, esempi utili.

Comportamento

Aderenza al prompt, tono, ripetizioni.

Prestazioni

Latenza, velocità token, carico RAM/CPU/GPU.

Il mio primo modello locale

- Avviare il modello da terminale
- Eseguire dei prompt di test
- Annotare velocità percepita
- Reasoning vs non-reasoning

I chatbot possono sbagliare benissimo

Allucinazioni, bias, contesto incompleto e sicurezza dipendono da modello, prompt e dati.

Regola pratica: verificare tutto ciò che ha conseguenze reali.


Intermezzo

Client: il “ChatGPT offline”

Ollama è il “motore”; il client è il “cruscotto”.

ChatGPT ≠ GPT

- ChatGPT: servizio con UI, account e strumenti
- LLM/GPT: modello che genera testo
- Il prodotto incapsula il modello



Scegliamo Page Assist

- Estensione browser
- Web UI per modelli locali
- Si collega a Ollama
- Comoda per demo live

Use your locally running AI models to assist you in your web browsing

chromewebstore.google.com/detail/...

chrome-extension

open-source

chat-application

localllm

ollama

📖 Readme

📄 MIT license

👤 Contributing

📈 Activity

★ 7.8k stars


👁 53 watching

🍴 738 forks

● CONNESSIONE

Client → Ollama serve

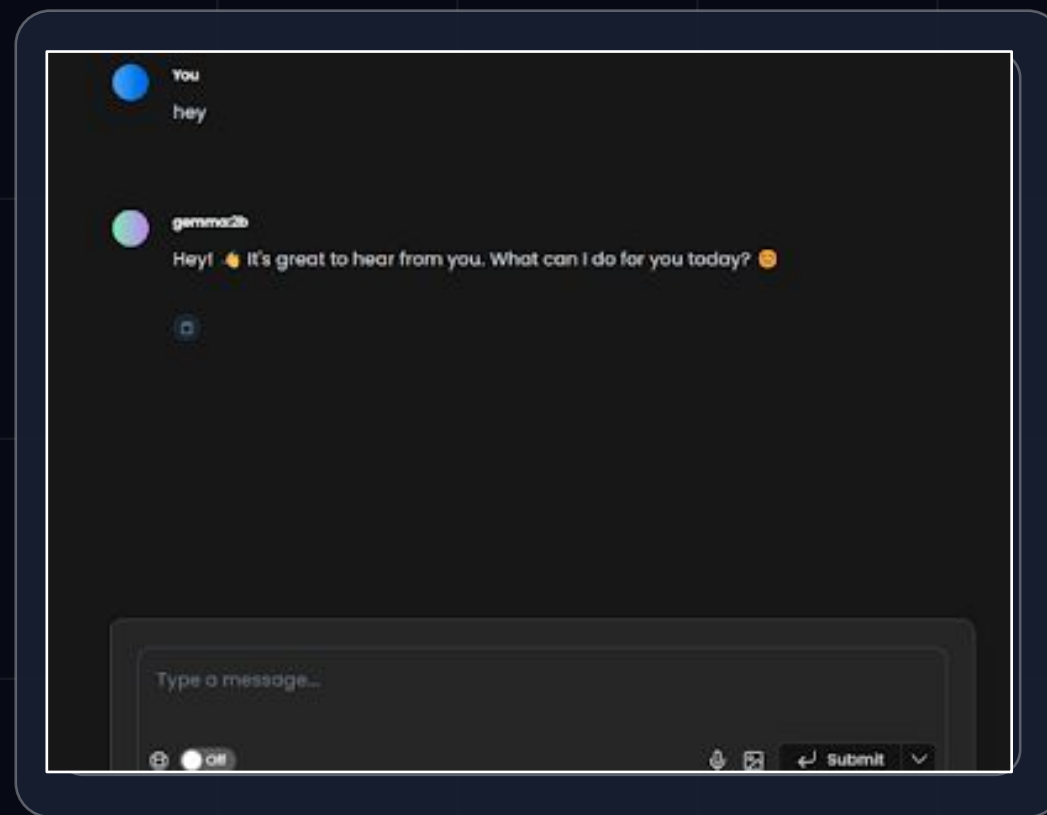
```
ollama serve  
# Page Assist → provider: Ollama  
# endpoint locale: http://localhost:11434
```



● DEMO CHAT

Prima conversazione

- Prompt semplice
- Risposta dal modello locale
- Controllare latenza e qualità



Cosa possiamo regolare?

Temperature

Creatività / casualità della risposta.

Context window

Quanto testo il modello vede insieme.

Max tokens

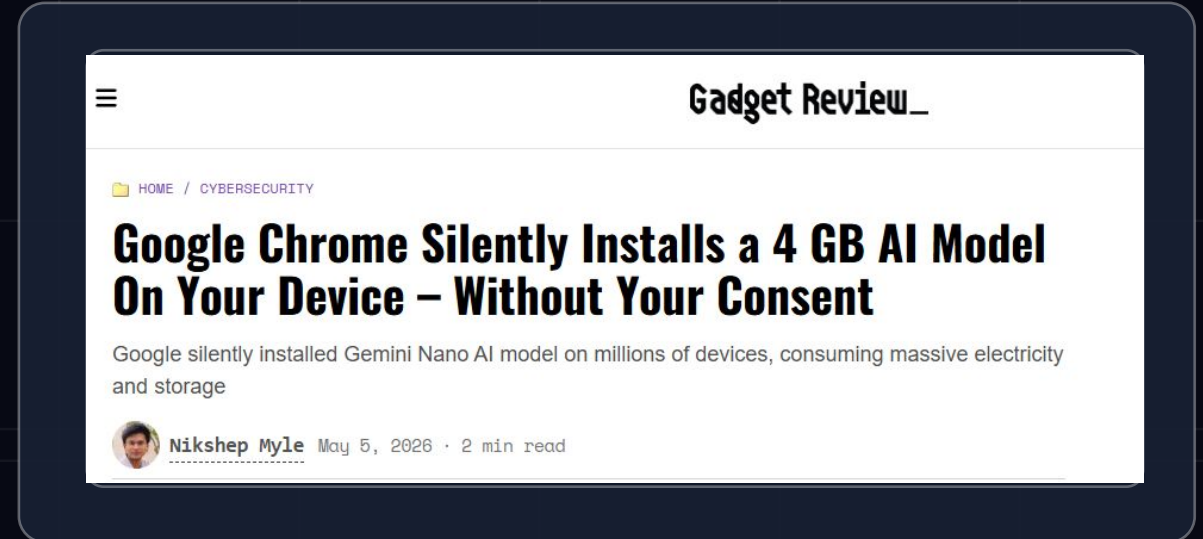
Lunghezza massima della risposta.

Il chatbot integrato nel browser

- Collegare Page Assist a Ollama
- Selezionare il modello
- Provare una conversazione
- Cambiare temperatura/context, showcase opzioni
- Caricare un file piccolo
- Caricare immagine
- Ricerca Web

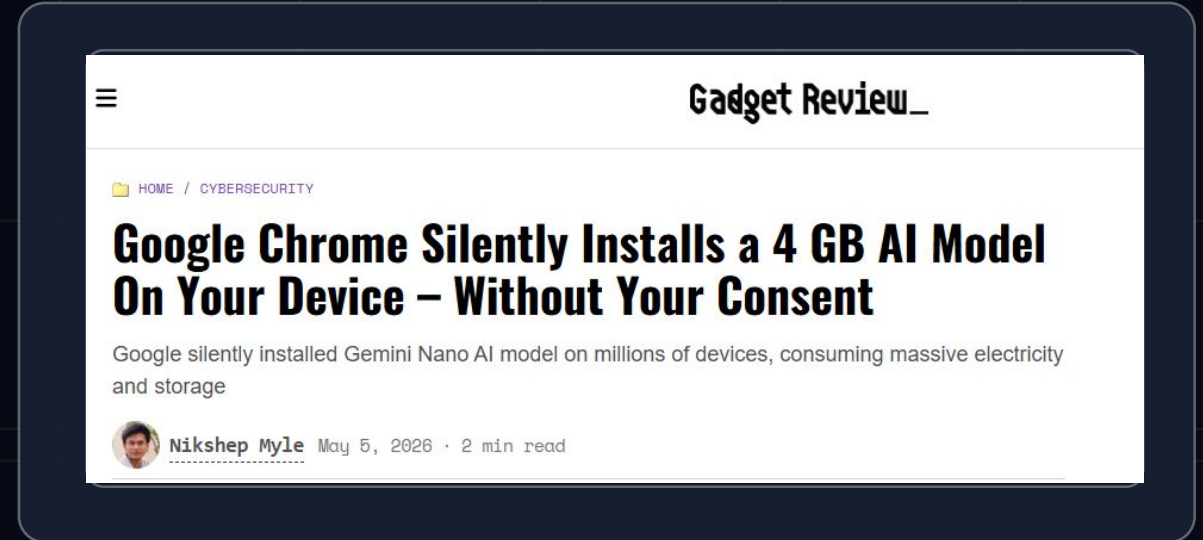
Il chatbot integrato nel browser

- Collegare Page Assist a Ollama
- Selezionare il modello
- Provare una conversazione
- Cambiare temperatura/context, showcase opzioni
- Caricare un file piccolo
- Caricare immagine
- Ricerca Web
- Integrazione Chrome e showcase funzioni



Il chatbot integrato nel browser


- Collegare Page Assist a Ollama
- Selezionare il modello
- Provare una conversazione
- Cambiare temperatura/context, showcase opzioni
- Caricare un file piccolo
- Caricare immagine
- Ricerca Web
- Integrazione Chrome e showcase funzioni
- Caricare un file grande...? E molti file?



● CONTEXT

Context window: cosa succede davvero?

- Documento piccolo: entra tutto nel prompt
- Documento grande: viene tagliato o riassunto male
- Contesto enorme: più lento e non sempre più accurato
- Serve recuperare solo i pezzi utili



Prompting vs fine-tuning

- Prompting: istruzioni nel contesto
- Fine-tuning: modifica del modello
- RAG: aggiunge documenti rilevanti

Fine-Tuning vs. Prompt Engineering



Fine-Tuning



Prompt Engineering

Intermezzo

RAG: Retrieval-Augmented Generation

Quando il contesto non basta, recuperiamo solo le parti rilevanti.

● IDEA BASE

RAG non è training o fine-tuning

Il modello non cambia: cambia il contesto che gli forniamo.

Retrieve


Augment

Generate

DEFINIZIONE

Cos'è il RAG?

- Retrieval: cerco pezzi rilevanti
- Augmented: li aggiungo al prompt
- Generation: il modello risponde usando il contesto



RAG workflow da TXT



Il punto: ogni passaggio prepara il testo per quello successivo. Se sbaglia chunking o retrieval, anche la risposta finale parte male.

Chunking


- Dividere documenti in pezzi gestibili
- Chunk troppo grandi: rumore
- Chunk troppo piccoli: perde contesto
- Overlap aiuta a non spezzare concetti

Chunk Size	Token Size	Ideal for
Small Chunks	200 - 300	Fact based queries like FQAs, short answers
Medium Chunks	400 - 800	Technical documents, Policies.
Large Chunks	1000+	Complex documents, research papers.

● EMBEDDING

Cos'è un embedding?

- Trasforma testo in vettore numerico
- Testi simili finiscono vicini
- Serve per cercare per significato
- La lingua e il dominio contano



● SEARCH

Vector vs hybrid vs match literal

Vector search

Cerca significato simile tramite embedding.

Literal search

Cerca parole esatte, utile per codici e nomi.

Hybrid search

Combina semantica e parole chiave.


● RERANK

Reranker

- Prende i risultati candidati
- Li riordina per rilevanza
- Costa più tempo ma può migliorare qualità
- Utile quando i primi risultati sono rumorosi

RANK 1

0.93



SPREADSHEET

Diabetes_Treatment_Outcomes

RANK 2

0.90



DOCUMENT

Patient_Treatment_Adherence

RANK 3

0.87



PDF

Diabetes_Management_Protocols

● KNOWLEDGE BASE

Knowledge base

- Archivio dei documenti indicizzati
- Contiene chunk + metadati
- Può essere locale o remota
- Va aggiornata quando cambiano i file



● OLLAMA

Scaricare modello embedding

```
ollama pull nomic-embed-text  
# oppure un embedding model compatibile  
# poi Page Assist / tool RAG lo usa per indicizzare
```

nomic-embed-text

📄 67.2M Downloads ⌚ Updated 2 years ago

A high-performing open embedding model with a large token context window.

[embedding](#)

[CLI](#) [cURL](#) [Python](#) [JavaScript](#)

```
ollama pull nomic-embed-text
```



Models

[View all →](#)

Name	Size	Context	Input
nomic-embed-text:latest	274MB	2K	Text
nomic-embed-text:v1.5 latest	274MB	2K	Text
nomic-embed-text:137m-v1.5-fp16	274MB	2K	Text

● ESEMPIO

Esempio pratico in Page Assist

- Carico un TXT o PDF piccolo
- Creo la knowledge base
- Faccio una domanda specifica
- Controllo se la risposta usa davvero il documento

RAG chatbot

What is a large language model?



Answer

A large language model is
...

Retrieve



```
{"dataset":  
  "aesthetic text focused"}
```

Quando RAG sbaglia

Retrieval

Recupera chunk sbagliati o incompleti.

Chunking

Pezzi troppo corti, lunghi o senza metadati.

Generazione

Il modello ignora o distorce le fonti.

● LIMITI

Limitazioni RAG

- Se il retrieval fallisce, la risposta parte male
- Documenti lunghi richiedono buona indicizzazione
- Serve aggiornare la knowledge base
- Citazioni e verifiche restano importanti



Mini RAG locale

- Scegliere TXT/PDF di varie dimensioni
- Creare o aggiornare knowledge base
- Fare delle domande specifiche
- Verificare se la risposta è nel documento

Cosa sapete fare ora

Installare, scegliere, eseguire, collegare e usare un LLM locale con documenti.

Ollama

Modelli

Page Assist

RAG

Limiti

Miglioramenti

● FINE

Fine lezione

Domande, debug residuo e prossimi esperimenti.

modelli più grandi

RAG migliore

valutazione

deploy locale