

Deep Leakage from Gradients

Analisi del Paper (NeurIPS 2019)

Autori: Ligeng Zhu, Zhijian Liu, Song Han (MIT)

Salvucci Franco

Mat. *0368692*

19 Giugno 2026

Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

1. Motivazione: Sicurezza nel Federated Learning

- **L'Assunzione Classica:** Nel *Distributed Training* (o Federated Learning), i dati di addestramento locali (es. immagini mediche) non lasciano mai il dispositivo dell'utente.
- **Condivisione "Sicura":** I dispositivi calcolano i gradienti (∇W) localmente e inviano *esclusivamente* quelli al server centrale.
- **Il Problema:** Fino al 2019, la comunità assumeva universalmente che i gradienti fossero intrinsecamente sicuri e impossibili da decifrare.
- **L'Obiettivo del Paper:** Colmare questo vuoto di sicurezza, dimostrando che condividere gradienti espone l'intero set di dati a una vulnerabilità critica.

Roadmap

- 1 Contesto
- 2 **Tesi principale**
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

2. Tesi Principale

Tesi dello Studio

"È possibile recuperare i dati privati di training estraendoli in modo analitico e accurato (pixel-wise / token-wise) dai gradienti condivisi pubblicamente."

Innovazione rispetto ai lavori precedenti (Baseline):

- Studi precedenti ("Shallow" Leakage, es. Melis et al.) usavano Modelli Generativi Avversariali (GAN) per estrarre informazioni.
- **Limite delle GAN:** Quei metodi riuscivano solo a generare immagini stilisticamente simili alla classe di appartenenza (es. un volto a caso), non il dato esatto.
- **Il metodo DLG** non usa reti generative, ma ottimizzazione matematica pura per estrarre il dato *identico* alla Ground Truth.

Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 **Algoritmo DLG**
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

3. Idea Chiave: L'Algoritmo DLG

Il processo si basa sull'ottimizzazione della distanza L_2 :

- 1 L'attaccante intercetta ∇W reale.
- 2 Genera "dummy data" (rumore) x' e label fittizia y' .
- 3 Calcola il "Dummy Gradient" $\nabla W'$ passando i dati finti nel modello.
- 4 Minimizza iterativamente la distanza tra $\nabla W'$ e ∇W aggiornando x' e y' .

Aggiornamento (Algoritmo 1):

$$\begin{aligned}x'_{i+1} &\leftarrow x'_i - \eta \nabla_{x'_i} \|\nabla W'_i - \nabla W\|^2 \\ y'_{i+1} &\leftarrow y'_i - \eta \nabla_{y'_i} \|\nabla W'_i - \nabla W\|^2\end{aligned}$$

Algorithm 1 Deep Leakage from Gradients.

Input: $F(x; W)$: Differentiable machine learning model; W : parameter weights; ∇W : gradients calculated by training data

Output: private training data x, y

```
1: procedure DLG( $F, W, \nabla W$ )  
2:    $x'_1 \leftarrow \mathcal{N}(0, 1), y'_1 \leftarrow \mathcal{N}(0, 1)$  ▷ Initialize dummy inputs and labels.  
3:   for  $i \leftarrow 1$  to  $n$  do  
4:      $\nabla W'_i \leftarrow \partial \ell(F(x'_i, W_t), y'_i) / \partial W_t$  ▷ Compute dummy gradients.  
5:      $\mathbb{D}_i \leftarrow \|\nabla W'_i - \nabla W\|^2$   
6:      $x'_{i+1} \leftarrow x'_i - \eta \nabla_{x'_i} \mathbb{D}_i, y'_{i+1} \leftarrow y'_i - \eta \nabla_{y'_i} \mathbb{D}_i$  ▷ Update data to match gradients.  
7:   end for  
8:   return  $x'_{n+1}, y'_{n+1}$   
9: end procedure
```

Normal Participant



Differentiable Model
 $F(x, W)$

$\rightarrow Pred \rightarrow$

$Loss \leftarrow$

$[0, 1, 0]$

∇W

Malicious Attacker



Differentiable Model
 $F(x', W)$

$\rightarrow Pred' \rightarrow$

$Loss' \leftarrow$

$[0.2, 0.7, 0.1]$

$\nabla W'$

Try to match

$\frac{\partial \mathbb{D}}{\partial X} \quad \mathbb{D} = \|\nabla W' - \nabla W\|^2 \quad \frac{\partial \mathbb{D}}{\partial Y}$

Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale**
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

4. Setup Sperimentale ed Evidenze

Come gli autori supportano l'algoritmo:

- **Modelli Usati:**
 - *Visione:* ResNet-56 (Modificata: attivazione **Sigmoid** invece di ReLU, rimozione degli stride per renderla differenziabile 2 volte).
 - *Linguaggio:* BERT (Task: Masked Language Model).
- **Dataset:** MNIST, CIFAR-100, SVHN e LFW (complessità crescente).
- **Ottimizzazione:** Algoritmo **L-BFGS** (richiede derivate del 2° ordine). 1200 iterazioni per le immagini, 100 per il testo.
- **Baseline & Metrica:** Confronto diretto con il metodo di Melis et al. [27]. Metrica di valutazione: **Mean Square Error (MSE)** tra l'immagine generata e l'originale.

Approfondimento



L-BFGS è un algoritmo di approssimazione usato per trovare i minimi di funzioni non lineari, particolarmente efficace per problemi di ottimizzazione ad alta dimensione come quello proposto da DLG. Più informazioni qui **L-BFGS**

Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati**
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

5.1 Risultati: Visione Artificiale

DLG esegue un processo convergente che trasforma il rumore nell'immagine esatta.



Il margine di errore (MSE) di DLG crolla sotto lo 0.03 su tutti i dataset testati, surclassando la baseline (MSE > 0.2).

5.2. Risultati: Dati Testuali (NLP)

Il testo è formato da token discreti (non differenziabili in modo continuo). DLG risolve ottimizzando lo spazio continuo degli *Embedding* e facendo reverse look-up.

Esempio ricostruzione su BERT (Tabella 1):

Iter.	Testo Ricostruito
0	<i>the the the the the the the the</i>
10	<i>the internal to to network , to the</i>
30	<i>the internal representations of network , to relate</i>

In sole 30-50 iterazioni, la sequenza estratta corrisponde quasi perfettamente alla Ground Truth.


Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size**
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

6. Limiti e Critica: L'Effetto del Batch Size

Un limite strutturale dell'attacco è la dipendenza dalla dimensione del batch (BS).

- Efficacia massima con batch limitati (ottimale a $BS = 1$).
- Aumentando il BS , i gradienti vengono sommati: l'ottimizzatore fatica a districare quali gradienti appartengono a quale immagine.
- Oltre $BS = 8$, subentrano gravi artefatti e l'attacco collassa.



Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese**
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

7. Strategie di Difesa

Sono state prese in considerazione diverse tecniche di difesa contro l'algoritmo DLG

- **Noisy Gradients**
- **Gradient Compression and Sparsification**
- Altre (es. Low Precision, Cryptology)


7.1 Noisy Gradients

Meccanismo:

- Si aggiunge rumore Gaussiano o Laplaciano ai gradienti (tecnica tipica della Differential Privacy).

Valutazione dell'efficacia:

- **Resilienza di DLG:** Il metodo tollera bene il rumore e recupera le immagini fino a una varianza di 10^{-3} .
- **Difesa efficace:** Fallisce solo con rumore ad altissima magnitudo (varianza $\geq 10^{-2}$).
- **Il Trade-off critico:** Per difendere il sistema (varianza 10^{-2}), l'accuratezza del modello crolla drasticamente (dal 76.3% al 45.3% su CIFAR-100).



7.2 Gradient Compression (Pruning)

Meccanismo:

- Consiste nell'azzerare (*pruning*) i gradienti con magnitudo più piccola prima della trasmissione.

Valutazione dell'efficacia:

- **Tolleranza massima:** DLG riesce a operare fino a un livello di sparsità del **20%**.
- **Difesa efficace:** Sopra il 20%, la mancanza di vettori blocca la convergenza di L-BFGS.
- **Il Vantaggio Pratico:** In letteratura, i gradienti possono essere compressi oltre il 99% (grazie alla Error Compensation) senza perdere accuratezza. È la **difesa raccomandata**.

7.3. Riassunto Efficacia delle difese

Tecnica di Difesa	Efficacia vs DLG	Impatto sul Modello
Rumore (DP)	Vulnerabile (se scala $\leq 10^{-3}$)	Crollo Accuracy se scala $\geq 10^{-2}$
Quantizzazione Int-8	Protetto	Crollo Accuracy (al 53%)
Gradient Pruning (> 20%)	Protetto	Nessun calo rilevante

Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza**
- 9 Domande aperte

8. Punti di Forza

- **Miglioramento netto sulle baseline:** Supera i limiti dei lavori precedenti (es. Hitaj e Melis), ottenendo precisione pixel-wise senza l'uso di GAN o conoscenze pregresse (prior) sul dataset.
- **Metodo Elegante:** La formulazione analitica minimizzando la L2 Loss è riproducibile e non dipende da modelli esterni ausiliari.
- **Generalizzabilità:** L'attacco è stato verificato in domini completamente diversi (Visione Computazionale con CNN e NLP con architetture Trasformer).
- **Impatto e Significatività:** Sconvolge completamente il paradigma di *privacy by design* su cui si basava l'industria.

Roadmap

- 1 Contesto
- 2 Tesi principale
- 3 Algoritmo DLG
- 4 Setup Sperimentale
- 5 Risultati
 - Risultati: Visione Artificiale
 - Risultati: Dati Testuali (NLP)
- 6 Vulnerabilità Batch Size
- 7 Difese
 - Noisy Gradients
 - Gradient Compression
 - Efficacia delle difese
- 8 Punti di Forza
- 9 Domande aperte

9. Spunti di Discussione e Domande Aperte

- **Il limite dell'architettura:** Gli autori hanno dovuto rimpiazzare ReLU con Sigmoid per avere derivate stabili al 2° ordine. In scenari industriali (dove si usa pesantemente ReLU), questa assunzione rende l'attacco meno realistico?
- **Baseline mancanti:** Il paper testa difese come l'aggiunta di rumore o il pruning. Sarebbe stato utile inserire un confronto diretto con difese più moderne come la *crittografia omomorfica* per vedere il trade-off computazionale?
- **Il batch size è una difesa intrinseca?** L'aumento del Batch Size manda l'ottimizzatore in confusione. È una soluzione definitiva o solo un limite temporaneo dei solver attuali (L-BFGS) che verrà superato in futuro?